实验 2：文档倒排索引算法

第一部分：实验设计说明

本部分共包括设计思路、算法设计、程序和各个类的设计说明。

1. 设计思路

倒排索引算法中每个倒排索引结构由一个词 term 和含有这个 term 的相关的多个 posting 列表组成，每个 posting 列表中包括单词 term 在一个具体的文档中出现的描述信息，包括文档名以及在该文档中的词频。经过这一步我们就会得到类似下面的索引结构：

<term, <doc1, tf1>…<docn,tfn>>

注：其中 doci 代表文档 i 的文件名，tfi 代表 term 在文档 i 中的词频；

再计算：平均出现次数= 词语在全部文档中出现的频数总和/包含该词语的文档数

对每个 term 在全部文档中出现的频数总和=$\sum_{i=1}^{n} tfi$

最后，得到索引结构：

<term\TAB 平均出现次数,doc1:tf1;doc2:tf2;...;docn:tfn>

2. 算法设计

Map 阶段：对每个文件每一行内容,进行处理得到诸如以下的多个键值对：<term#filename,num>,下面是 Map 阶段的伪代码：

```
Class Mapper
```

```
      //for a line
      for all term t in line do
        Key <- term + “#” + filename
        Emit(key, 1)
Class Combiner:
      //process same key
      sum <- 0
      for all value in same key
          sum += value
     Emit(key, sum)
Class Partitioner
    //shuffle key-value
    //for all key-value do
     newKey <- term //get term form key
     do Partitioner with newKey…
```

Reduce 阶段：经过 Map 阶段，相同的 term 都被发送到了同一个 Reduce 节点。根据输出的 key 信息，可以得到 term 在每个文档中出现的词频，进而可以计算出 term 的平均出现次数。

```
Class Reduce
   //for key-value→<term#doci, num>
   //canculate tf of term in doci
    tfi <- 0
       for all term in doci
           tfi += value;
       get <doci, tfi>
       //计算平均出现次数
       total <- 0
       for  tfi of term in all doc
           total += tfi
       average <- totoal / n
       key <- term
       value<-average+“,”+doci:tfi+“;”+…+“;” +docn:tfn
       Emit(key, value)
```

3. 程序以及各个类的设计说明

程序中包括以下类：

FileNameInputFormat：是一个自定义 FileInputFormat，将

作业数据分割成多个 InputSpilt。

FileNameRecordReader：是一个自定义 RecordReader,将 InputSpilt 处理转化为若干的输入记录；

InvertedIndexMapper：对 filename 进行处理得到诸如<term#filename, 1>的多个键值对。

SumCombiner：在 Mapper 阶段会产生大量的相同主键的键值对，因此需要使用 Comnbiner 对 Mappper 部分的中间结果的词频进行累加，减少向 Reduce 节点传输的数据量。

NewPartitioner：由于 Key 值为 term+filename,若使用默认的 Partitioner 进行 shuffle 处理，同一个 term 可能会被发送到不同的 Reduce 节点。所以需要将原有的 key 处理，单使用 term 作为新的 key 进行 Partitioner,这样就可以保证所有相同的 term 被发送到同一个 Reduce 节点。

InvertedIndexReducer：自定义的 Reducer 类。对上一步的中间结果<term#filename, num>进行处理，得到 term 在每个文档中对应出现的词频，再计算 term 的平均出现次数。这里注意处理最后一个单词。得到：

Term average_times,doc1:tf1;…;docn:tfn

第二部分：运行与结果分析

本部分共包括实验运行和实验结果说明和分析。

1. 实验运行

在 eclipse 中打包程序 InvertedIndexer.jar

在集群中提交,运行时 Jobtracker WebUI 截图：

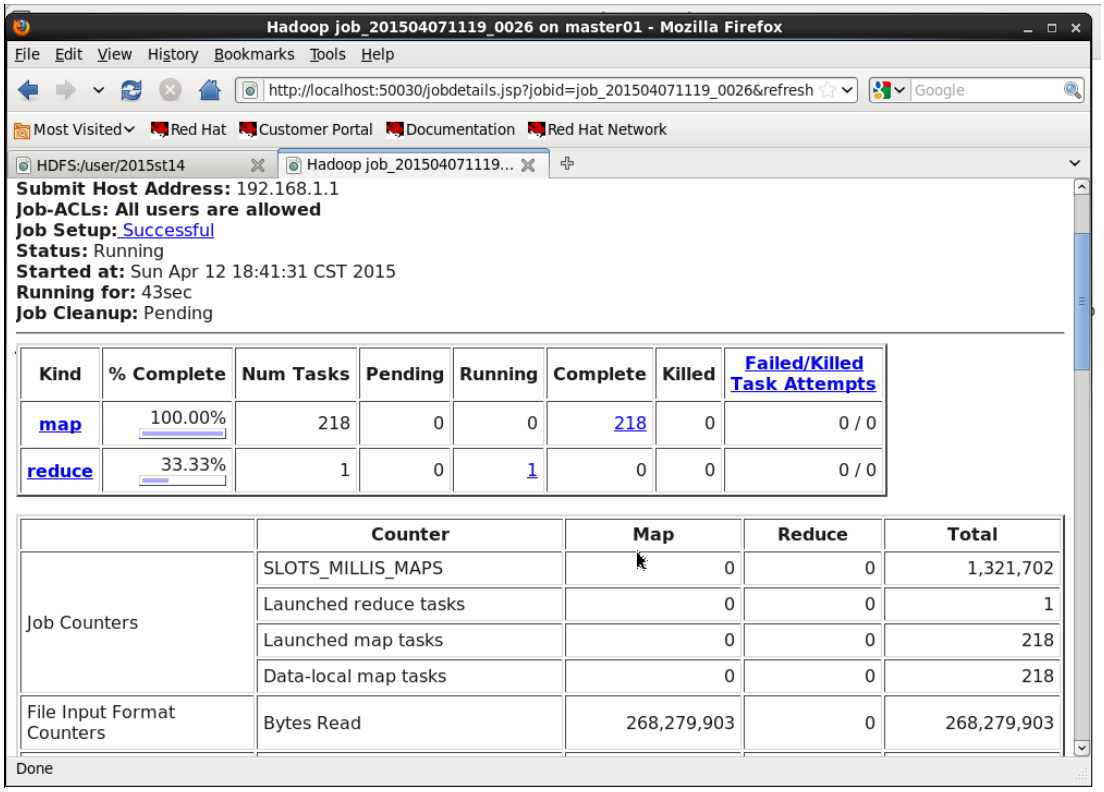

运行成功截图：

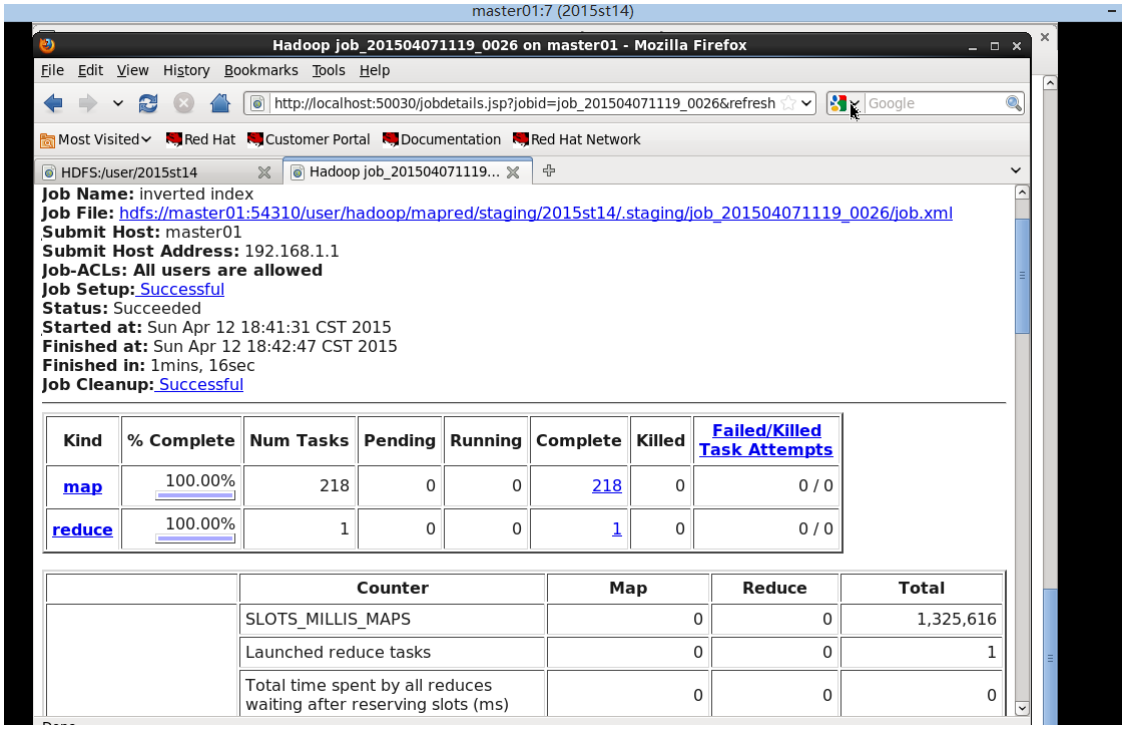

2. 实验结果说明和分析

实验结果截图：

实验结果中索引结构 term\t 平均出现次数，doc1:tf1;…，对词语 1 月进行分析，发现其在两个文档中分别出现了两次，故其平均出现次数为 2.0.

第三部分：不足与改进

本部分共包括实验中性能扩展性等方面的可能存在的不足和可能的可进。

1. 可能存在的不足

   实验结果中包含了较多的停用词信息，比如数字等。

2. 可能的改进

   对停用词进行处理。

附件：

附件 1：源程序 InvertedIndexer.java

附件 2: 运行程序 InvertedIndexer.jar

附件 3：结果文件 exp2_2015st14_out